

פרויקט בקורס 67731 - אופטימיזציה קמורה

יאן טל ולולה (לאונה) רפפורט

05/06/2022

1 מידע אישי

שמות הסטודנטים: יאן טל (ת.ז.) ולולה (לאונה) רפפורט (ת.ז.)

אנו לומדים לימודי מוסמך.

2 הוכחת שקילות

על מנת לפתור את הבעיה הנתונה השתמשנו בשתי שיטות: Projected Gradient Decent ו-Interior Point (נקראת גם Barrier Method ובה נעשה שימוש בשיטת ניוטון).

בבעיה המקורית נתונים $y \in \mathbb{R}^m$ ומטריצה $H \in \mathbb{R}^{m \times n}$, והמטרה היא לפתור את הבעיה המוגדרת כך:

$$\begin{aligned} x^* &= \arg \min_{x \in \mathbb{R}^n} \|y - Hx\|_2 \\ s.t. \quad \vec{1}^T x &= 1 \\ x &\geq 0 \end{aligned}$$

עבור כל אחת משתי השיטות פתרנו בעיה שקולה שונה. האלגוריתם שלנו בוחר להשתמש באחת מן השיטות בכפוף למספר המצב של הבעיה. כעת, עבור כל שיטה נפרט על אופן קבלת הבעיה השקולה ונוכיח את שקילותה.

2.1 Interior Point

כזכור, הבעיה המקורית הינה:

$$\begin{aligned} x^* &= \arg \min_{x \in \mathbb{R}^n} \|y - Hx\|_2 \quad (0) \\ s.t. \quad &\vec{1}^T x = 1 \\ &x \geq 0 \end{aligned}$$

טענה: בעיה זו שקולה לבעיה הבאה:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad &\frac{1}{2} \|y - Hx\|_2^2 \quad (1) \\ s.t. \quad &\vec{1}^T x = 1 \\ &x \geq 0 \end{aligned}$$

הערה: הבעיה (1) היא למעשה הבעיה שפתרנו בשיטת Projected Gradient Decent.

הוכחת השקילות: ראשית, פונקציית המטרה המקורית היא אי-שלילית מתכונות הנורמה. לכן, כפל בסקלר חיובי אינו משנה את הפתרון האופטימלי. בנוסף, עבור שני מספרים אי-שליליים $a, b \geq 0$, אם $a \leq b$ אזי $a^2 \leq b^2$. מכאן שהעלאה בריבוע אינה משנה את הפתרון האופטימלי. לבסוף, ברור כי אם $x \geq 0$ אזי $-x \leq 0$ איבר-איבר, על ידי כפל ב-1. מכאן שהבעיה המקורית שקולה לבעיה (1). ■

כעת, נגדיר את קבוצת אילוצי האי-שוויון $Q = \{x \in \mathbb{R}^n : -x_i \leq 0, \forall i \in [n]\}$ ונשתמש ב-Barrier ואז נקבל:

$$\text{Barrier}(x) = \begin{cases} \infty & x \notin Q \\ 0 & \text{else} \end{cases}$$


נשנה את פונקציית המטרה ונקבל את הבעיה:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad &\frac{1}{2} \|y - Hx\|_2^2 + \text{Barrier}(x) \quad (2) \\ s.t. \quad &\vec{1}^T x = 1 \end{aligned}$$

מתקיים שהפתרון האופטימלי הוא בפרט פתרון פיזיבילי המקיים את אילוצי האי-שוויון. אולם, בבעיה (2) התנאי הוא תקף בהגדרת הפונקציה עצמה ולא מופיע בתור אילוץ של הבעיה. אנו מימשנו את ה-Barrier לפי פונקציית log, כאשר מתקיים:

$$-\log(x_i) = \begin{cases} \infty & \text{else} \\ -\log(x_i) & x_i > 0 \end{cases}$$

נסמן: $f(x_i) = -\log(x_i)$.



איור 1: הגרף של הפונקציה $f(x) = -\log(x)$

על מנת לדרוש ש- $-\log(x_i)$ יהיה קרוב לאפס נחלק ב- tol גדול מספיק ואז נקבל:

$$-\frac{1}{\text{tol}} \log(x_i) = \begin{cases} \infty & \text{else} \\ -\frac{1}{\text{tol}} \log(x_i) & x_i > 0 \end{cases}$$

כאשר $\varepsilon > 0$ עבור $-\frac{1}{\text{tol}} \log(x_i) < \varepsilon$ מכאן נקבל את הבעיה הבאה:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|y - Hx\|_2^2 - \sum_{i=1}^n \frac{1}{\text{tol}} \log(x_i) \quad (3) \\ \text{s.t.} \quad & \vec{1}^T x = 1 \end{aligned}$$

2.2 Projected Gradient Decent

כפי שצוין לעיל, הבעיה השקולה שפתרנו בשיטת Projected Gradient Decent היא :

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|y - Hx\|_2^2 \\ \text{s.t.} \quad & \vec{1}^T x = 1 \\ & x \geq 0 \end{aligned}$$

3 האלגוריתם

כפי שצוין לעיל, עבור האלגוריתם שלנו אנו בחרנו להשתמש בשני אלגוריתמים : Projected Gradient Decent ו-Interior Point.

3.1 הסיבות לבחירת האלגוריתם

כעת, נציין מדוע בחרנו להשתמש בכל אחת משתי השיטות. בחרנו להשתמש בשיטת Interior Point שבה נעשה שימוש בשיטת ניוטון, לאור העובדה ששיטה זו מתכנסת די מהר (מדובר בשיטה מסדר שני). אולם, מדובר בשיטה מאוד יקרה, מאחר שקירוב מסדר שני דורש שימוש בהסיאן, אשר יכול להיות מאוד גדול. בעיה נוספת היא שבחירת tol גדול אמור באופן תאורטי לשפר את הקירוב ולגרום לכך ש- log יהיה קרוב מאוד לפונקציית ה-Barrier, שכן log היא פונקציה חלקה יחסית. בפועל, בחירת tol גדול גורמת לטעויות נומריות רבות ומאריכה את זמן הריצה. לכן בחרנו tol של 10000. נעיר ש- tol זה גורם לכך שהוקטור המוחזר יחרוג מעט מהאילוץ $x_i \geq 0$ לכל $i \in [n]$, אך בתמורה ההתכנסות תהיה מהירה ועם פחות טעות.

בניגוד ל-Interior Point, ב-Projected Gradient Decent לעולם לא נחרוג, אף לא מעט, מאילוץ האי-שוויון. שיטה זו היא מהירה עבור מספרי מצב נמוכים של ההסיאן. כמו כן, הקירוב המוחזר בשיטה זו יהיה קרוב מאוד לפתרון האופטימלי עבור גודל צעד קטן מספיק ועם לכל היותר 1000 איטרציות.

לפיכך, החלטנו להשתמש בשתי השיטות הללו לסירוגין עבור האלגוריתם שלנו בכפוף למספר המצב של $H^T H$, ההסיאן של הבעיה (1) השקולה לבעיה המקורית.

3.2 אופן אימון האלגוריתם

על מנת לשפר את הביצועים אימנו את האלגוריתם באופן הבא : ראשית, אנחנו החלטנו להפעיל את שיטת Interior Point רק עבור מטריצות $H^T H$ עם מספרי

מצב גדולים מספיק. לאור העובדה שעבורם קירוב מסדר שני מאוד יקר ודורש זמן ריצה רב, החלטנו שהאלגוריתם יעצור ויחזיר פתרון אם אחד משני התנאים מתקיימים:

$$1. \quad \|F(v)\|_2 \leq 2.01, \text{ ראה תת-סעיף 4.1, כאשר כאן קבענו } \varepsilon = 2.01.$$

2. כאשר הצעד הנוכחי + הצעד הבא אינו פתרון פיזיבילי, הצעד הנוכחי מוחזר בתור פתרון.

לפי הדוגמאות, הבחנו שזה כנראה מספיק טוב או מספיק קרוב לפתרון האופטימלי.

עבור הרצת Projected Gradient Decent קבענו שדי ב-1000 איטרציות. מספר זה בעינינו גדול מספיק וכן עבורו זמן הריצה נשאר קטן. תופעה שנתקלנו בה היא שוקטור הפתרון נעשה דליל מדי (sparse) ובפרט בעל קואורדינטה היחידה עם הערך 1 ויתר הקואורדינטות עם הערך 0. משם, כל איטרציה נוספת אינה תשנה את וקטור הפתרון. החלטנו עדיין להחזיר וקטור כזה בתור פתרון, שכן אנו גורסים שבמקרה זה הפתרון האופטימלי אינו מקיים את האילוצים ונמצא מחוץ לסימפלקס האילוצים. אנו מאמינים שהוקטור הנ"ל מציין את כיוון הפתרון האופטימלי הנמצא מחוץ לסימפלקס האילוצים על ידי אותה הקואורדינטה היחידה.

כמו כן, עבור Projected Gradient Decent בחרנו את הצעד ההתחלתי x_0 להיות ההטלה לאילוצים של הפתרון לבעיה הלא מאולצת, כאשר אותה פתרנו בשיטת הריבועים הפחותים (ראה תת-סעיף 4.2). לעומת זאת, מפאת העובדה שאותו x_0 עשוי להכיל קואורדינטה עם הערך 0 וכן שב-Interior Point נדרש ש- x_0 יהיה בפנים ולא על השפה, בחרנו את x_0 להיות

$$\frac{1}{n} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}, \text{ כלומר וקטור באורך } n \text{ של } \frac{1}{n}. \text{ אכן, } x_i > 0 \text{ לכל } i \in [n] \text{ וגם } \vec{1}^T x = 1, \text{ משמע מדובר בצעד התחלתי פיזיבילי הנמצא בפנים ולא על השפה.}$$

3.3 התחשבות האלגוריתם במטריצה H

האלגוריתם שלנו אכן מתחשב במטריצה H . האלגוריתם אינו מתחשב ישירות במימד המטריצה H , אלא במספר המצב של $H^T H$, ההסיאן של הבעיה (1) המהווה בעיה שקולה לבעיה המקורית. אנו קבענו סף על מספר המצב של $H^T H$ של 2200000000, כך שאם מספר המצב גדול ממש ממנו האלגוריתם יבצע את שיטת Interior Point, אחרת האלגוריתם יבצע את שיטת Projected Gradient Decent. הסף נקבע על פי ניסוי וטעיה, כאשר בחנו את מספרי המצב המתקבלים עבור הבעיות לדוגמה. ריכזנו כרשימה את הערכים שהתקבלו באיור 2:

0	867187.8567186939
1	1795785.9587556836
2	1561430.2560397023
3	561407574.1682363
4	2126116418.5573099
5	1459399668.9269109
6	3406939877451.388
7	1381946.8300356898
8	5878184.905027274
9	657774.4233595256
10	1213606893.049332
11	965540510.1366327
12	922663280.739778
13	1400337548675.4512

איור 2 : רשימת ערכי מספרי המצב המתקבלים עבור הבעיות לדוגמה

מתוך התבוננות בערכי מספרי המצב שהתקבלו עבור לבעיות לדוגמה, שמנו לב שסך זה מטיב את הביצועים של האלגוריתם על הבעיות לדוגמה ולכן הוא נקבע. בתת-סעיף 4.3 מוגדר מספר מצב וכן מפורט מדוע Projected Gradient Decent רגיש למספר המצב של ההסיאן של הבעיה.

3.4 עצירת האלגוריתם והחזרת תשובה

כאמור, אם האלגוריתם משתמש בשיטת Projected Gradient Decent אזי מספר המצב של $H^T H$ מספיק קטן והאלגוריתם יעצור ויחזיר תשובה לאחר 1000 איטרציות או בצעד בו מתקבל וקטור דליל מדי כמתואר לעיל. אחרת, אם האלגוריתם משתמש בשיטת Interior Point אז האלגוריתם יעצור ויחזיר תשובה כאשר $\|F(v)\|_2 \leq 2.01$, או כאשר הצעד הנוכחי + הצעד הבא אינו פיזיבילי ואז הצעד הנוכחי יוחזר בתור הפתרון.

4 נספחים - פיתוחים תאורטיים

כעת, נציג את הפיתוח התאורטי מאחורי השיטות שהשתמשנו בהן וכן את חשיבות מספר המצב של ההסיאן של הבעיה.

4.1 Interior Point

נחשב את הגרדיאנט של פונקציית המטרה של הבעיה (3). נעשה זאת באופן ספרבילי. כלומר, נחשב את הגרדיאנט של $\frac{1}{2} \|y - Hx\|_2^2$ ולאחר מכן נחשב את הגרדיאנט של $-\frac{1}{\text{tol}} \sum_{i=1}^n \log(x_i)$ ואז נחבר אותם. מתקיים:

$$\nabla \left(\frac{1}{2} \|y - Hx\|_2^2 \right) = H^T(Hx - y) = H^T Hx - H^T y$$

לשם הפשטות, באלגוריתם שלנו שמרנו בזיכרון את $H^T Hx$ ואת $H^T y$ בתור מטריצות B ו- C בהתאמה. כמו כן, שמרנו בזיכרון מטריצה A המקיימת $Ax = b$ בתור אילוף. במקרה שלנו האילוף הוא $\vec{1}^T x = 1$, כלומר A הוא וקטור שורה ומתקיים $A = \vec{1}^T$ ו- $b = 1$. בנוסף,

$$\nabla \left(-\frac{1}{\text{tol}} \sum_{i=1}^n \log(x_i) \right) = -\frac{1}{\text{tol}} \nabla \left(\sum_{i=1}^n \log(x_i) \right) = -\frac{1}{\text{tol}} \begin{pmatrix} \frac{1}{x_1} \\ \frac{1}{x_2} \\ \vdots \\ \frac{1}{x_n} \end{pmatrix}$$

בסה"כ קיבלנו שהגרדיאנט של פונקציית המטרה הינו:

$$H^T Hx - H^T y - \frac{1}{\text{tol}} \begin{pmatrix} \frac{1}{x_1} \\ \frac{1}{x_2} \\ \vdots \\ \frac{1}{x_n} \end{pmatrix}$$

נסמן זאת ב- $\nabla f(x)$. כעת, נחשב את הגרדיאנט של פונקציית המטרה של הבעיה (3). נעשה זאת באופן ספרבילי. כלומר, נחשב את הגרדיאנט של $\frac{1}{2} \|y - Hx\|_2^2$ ולאחר מכן נחשב את הגרדיאנט של $-\frac{1}{\text{tol}} \sum_{i=1}^n \log(x_i)$ ואז נחבר אותם. מתקיים:

$$\nabla \left(\frac{1}{2} \|y - Hx\|_2^2 \right) = H^T(Hx - y) = H^T Hx - H^T y$$

לשם הפשטות, באלגוריתם שלנו שמרנו בזיכרון את $H^T Hx$ ואת $H^T y$ בתור מטריצות B ו- C בהתאמה. כמו כן, שמרנו בזיכרון מטריצה A המקיימת $Ax = b$ בתור אילוף. במקרה

שלנו האילוץ הוא $\vec{1}^T x = 1$, כלומר A הוא וקטור שורה ומתקיים $A = \vec{1}^T$ ו- $b = 1$. בנוסף,

$$\nabla \left(-\frac{1}{\text{tol}} \sum_{i=1}^n \log(x_i) \right) = -\frac{1}{\text{tol}} \nabla \left(\sum_{i=1}^n \log(x_i) \right) = -\frac{1}{\text{tol}} \begin{pmatrix} \frac{1}{x_1} \\ \frac{1}{x_2} \\ \vdots \\ \frac{1}{x_n} \end{pmatrix}$$

בסה"כ קיבלנו שהגרדיאנט של פונקציית המטרה הינו: נמצא את הלגראנז'יאן:

$$\begin{aligned} \min_x f(x) \\ \Rightarrow \mathcal{L}(x, \lambda) = f(x) + \lambda^T h(x) \\ \text{s.t. } h(x) = 0 \end{aligned}$$

נגזור את הלגראנז'יאן לפי x ונקבל:

$$\nabla_x \mathcal{L}(x, \lambda) = \nabla f(x) + \nabla h^T(x) \lambda$$

הפתרון האופטימלי מקיים:

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) + \nabla h^T(x^*) \lambda^* = 0 \quad (4)$$

בנוסף, האילוץ מקיים $h(x^*) = 0$. במקרה שלנו: $h(x) = Ax - b = \vec{1}^T x - 1$.

נשים לב ש- $\nabla f(x)$ הוא וקטור מממד n , לכן גם $\nabla h^T(x) \lambda$ הוא וקטור מממד n . הלגראנז'יאן

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) + \nabla h^T(x^*) \lambda^* = 0$$

מהווה מערכת משוואות עם n משוואות. כמו כן, $h(x^*) = 0$ מהווה מערכת משוואות עם m משוואות, כאשר במקרה שלנו $m = 1$. בסה"כ יש לפתור מערכת של $n + m$ משוואות. נזכר כי קירוב מסדר שני מקיים:

$$f(x_{k+1}) = f(x_k) + \nabla f(x_k)^T \Delta x + \frac{1}{2} \Delta x^T \nabla^2 f(x_k) \Delta x$$

כאשר $x_{k+1} = x_k + \Delta x$.

על מנת להגיע לקירוב זה יש למצוא את ההסיאן. לשם כך, בדומה לחישוב הגרדיאנט נעשה זאת באופן ספרבילי:

$$\begin{aligned} \nabla^2 \left(\frac{1}{2} \|y - Hx\|_2^2 \right) &= D \left[\nabla \left(\frac{1}{2} \|y - Hx\|_2^2 \right) \right] = D [H^T (Hx - y)] \\ &= H^T D [Hx - y] = H^T H \end{aligned}$$

כמו כן,

$$\begin{aligned} \nabla^2 \left(-\frac{1}{\text{tol}} \sum_{i=1}^n \log(x_i) \right) &= D \left[-\frac{1}{\text{tol}} \begin{pmatrix} \frac{1}{x_1} \\ \vdots \\ \frac{1}{x_n} \end{pmatrix} \right] = -\frac{1}{\text{tol}} D \left[\begin{pmatrix} \frac{1}{x_1} \\ \vdots \\ \frac{1}{x_n} \end{pmatrix} \right] \\ &= -\frac{1}{\text{tol}} \begin{pmatrix} -\frac{1}{x_1^2} & 0 & 0 & \cdots & 0 \\ 0 & -\frac{1}{x_2^2} & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & 0 & \cdots & -\frac{1}{x_n^2} \end{pmatrix} = -\frac{1}{\text{tol}} \text{Diag} \left(-\frac{1}{x^2} \right) = \frac{1}{\text{tol}} \text{Diag} \left(\frac{1}{x^2} \right) \end{aligned}$$

כאשר $\frac{1}{x^2}$ הוא איבר-איבר ו-Diag היא מטריצה אלכסונית עם $\frac{1}{x_i^2}$ באיבר ה- (i, i) .
בסה"כ:

$$\nabla^2 f(x) = H^T H + \frac{1}{\text{tol}} \text{Diag} \left(\frac{1}{x^2} \right)$$

כעת, נעשה קירוב מסדר ראשון ל- $h(x)$, מאחר שקירוב מסדר שני שווה לקירוב מסדר ראשון, בהינתן ש- h אפינית. מתקיים:

$$h(x_{k+1}) \approx h(x) + \nabla h(x)^T \Delta x$$

כאשר $x_{k+1} = x + \Delta x$.
מכאן נקבל שהבעיה המקורבת שלנו הינה:

$$\begin{aligned} \min_{\Delta x \in \mathbb{R}^n} & f(x) + \nabla f(x)^T \Delta x + \frac{1}{2} \Delta x^T \nabla^2 f(x) \Delta x \\ \text{s.t.} & h(x) + \nabla h(x)^T \Delta x = 0 \end{aligned}$$

הלגראנזיאן החדש שנקבל הינו:

$$\tilde{\mathcal{L}}(x, \lambda) = f(x) + \nabla f(x)^T \Delta x + \frac{1}{2} \Delta x^T \nabla^2 f(x) \Delta x + \lambda^T (h(x) + \nabla h(x)^T \Delta x)$$

הגרדיאנט של הלגראנזיאן לפי Δx הינו:

$$\nabla_{\Delta x} \tilde{\mathcal{L}}(x, \lambda) = \nabla f(x) + \nabla^2 f(x) \Delta x + \nabla h(x)^T \lambda$$

כאשר ב- (x^*, λ^*) נקבל אפס. נזכור שהאילוץ הוא $h(x) + \nabla h(x)^T \Delta x = 0$. כעת, יש לפתור את המערכת:

$$\begin{cases} \nabla f(x^*) + \nabla^2 f(x^*) \Delta x + h(x^*)^T \lambda^* = 0 & \text{משוואות } n \\ h(x^*) + \nabla h(x^*)^T \Delta x = 0 & \text{משוואות } m \end{cases}$$

נעביר אגפים :

$$\begin{cases} \nabla^2 f(x^*) \Delta x + \nabla h(x^*)^T \lambda^* = -\nabla f(x^*) \\ \nabla h(x^*)^T \Delta x = -h(x^*) \end{cases}$$

נקבל :

$$\begin{bmatrix} \nabla^2 f(x) & \nabla h(x) \\ \nabla h(x)^T & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \lambda \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ h(x) \end{bmatrix}$$

ניתן להחליף את $h(x)$ ב-0, מאחר שכך כל פתרון יהיה פיזיבילי, כלומר שייך ל- $\ker(h)$.
 בכל איטרציה נמצא Δx ונעדכן $x \leftarrow x + \Delta x$. כעת, נסביר כיצד ניתן לחסום את האיטרציות.
 נשתמש בגרדיאנט של הלגראנז'יאן הראשון שחישבנו הנתון ב-(4) ובאילוץ המתאים $h(x^*) = 0$. מתקיים :

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) + \nabla h(x^*)^T \lambda^* = 0, \quad h(x^*) = 0$$

נחפש ערכים על מנת לאפס את המערכת :

$$\begin{cases} \nabla_x \mathcal{L}(x, \lambda) = \vec{0} \\ h(x) = \vec{0} \end{cases}$$

לשם כך, נגדיר וקטור $v = \begin{bmatrix} x \\ \lambda \end{bmatrix}$ ופונקציה $F(v) = \begin{bmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ h(x) \end{bmatrix}$ ונפתור $F(v) = 0$ בעזרת ניוטון-רפסון, כלומר :

$$F(v_k) + \frac{\partial F}{\partial v}(v_k)(v - v_k) = 0$$

$$\Rightarrow \begin{cases} \nabla_x \mathcal{L}(x_k, \lambda_k) + \nabla_x^2 \mathcal{L}(x_k, \lambda_k)(x - x_k) + \nabla h(x_k)(\lambda - \lambda_k) = 0 \\ h(x_k) + \nabla h(x_k)^T(x - x_k) = 0 \end{cases}$$

נזכור שמהגדרה $\Delta x = x - x_k$ ו- $\Delta \lambda = \lambda - \lambda_k$ ואם נעביר אגפים את $\nabla_x \mathcal{L}(x_k, \lambda_k)$ ואת $h(x_k)$ נקבל את המערכת :

$$\begin{bmatrix} \nabla_x^2 \mathcal{L}(x, \lambda) & \nabla h(x) \\ \nabla h(x)^T & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta \lambda \end{bmatrix} = - \begin{bmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ h(x) \end{bmatrix} \quad (*)$$

על מנת לחסום את האיטרציות ניתן להתחיל ב- (x_0, λ_0) ולהמשיך עד אשר $\|F(v)\|_2 \geq \varepsilon$.
 להלן האלגוריתם :

```

1: while  $\|F(v)\|_2 > \varepsilon$  do
2:   Solve  $(\star)$ 
3:    $x \leftarrow x + \Delta x$ 
4:    $\lambda \leftarrow \lambda + \Delta \lambda$ 
5: end while

```

4.2 Projected Gradient Decent

כעת, נסביר כיצד בחרנו x_0 יחסית טוב בשיטת Projected Gradient Decent. אנחנו הגדרנו את x_0 להיות הפתרון של

$$\min_{x \in \mathbb{R}^n} \|y - Hx\|_2^2$$

באמצעות ריבועים פחותים ועל הפתרון המתקבל ביצענו הטלה המוגדרת באופן הבא: נביט בלגרנז'יאן של בעיית ההטלה

$$\begin{aligned} \text{Projection problem: } \min_{x \in \mathbb{R}^n} & \frac{1}{2} \|x - y\|_2^2 \\ \text{s.t. } & \vec{1}^T x = 1 \\ & x \geq 0 \end{aligned}$$

ונתעלם מאילוץ האי-שוויון:

$$\mathcal{L}(x, \lambda) = \frac{1}{2} \|x - y\|_2^2 + \lambda(\vec{1}^T x - 1)$$

כאשר $h(x) = \vec{1}^T x - 1$ אשר ראינו קודם. נמזער את כל ההטלות ב- x תוך כדי שמירה על אילוץ האי-שוויון:

$$\begin{aligned} \min_{x \geq 0} \mathcal{L}(x, \lambda) &= \frac{1}{2} \|x - y\|_2^2 + \lambda(\vec{1}^T x - 1) = \\ &= \sum_{i=1}^n \left[\frac{1}{2} (x_i - y_i)^2 + \lambda x_i \right] - \lambda \end{aligned}$$

נראה כי λ – בלתי תלוי ב- x ולכן הוא אינו משפיע על פתרון הבעיה. מכאן נקבל בעיה שקולה:

$$\min_{x \geq 0} \sum_{i=1}^n \left[\frac{1}{2} (x_i - y_i)^2 + \lambda x_i \right]$$

נרצה למזער את $\min_{x \geq 0} \sum_{i=1}^n \left[\frac{1}{2}(x_i - y_i)^2 + \lambda x_i \right]$ לכל $i \in [n]$, לכן נגזור ונשווה לאפס:

$$\frac{\partial \left(\frac{1}{2}(x_i - y_i)^2 + \lambda x_i \right)}{\partial x_i} = x_i - y_i + \lambda = 0$$

נקבל את הפתרון $x_i = y_i - \lambda$. לפיכך, נקבל שאם $y_i - \lambda \geq 0$, אזי x_i פיזיבילי ולכן אופטימלי. אחרת, נבחר $x_i = 0$, שכן הוא כמובן האופטימלי והוא גם כן פיזיבילי. לכן, בסה"כ הפתרון האופטימלי הינו:

$$x_i = \max \{y_i - \lambda, 0\}, \quad \forall i \in [n]$$

על מנת למצוא את λ נתבונן בסכום $S \triangleq \sum_{i=1}^n x_i$. מהאילוץ $x \geq 0$, הסכום S אינו אי-שלילי, כלומר $S \geq 0$. מהפתרון הקודם מתקיים כי:

$$\sum_{i=1}^n x_i = \sum_{i=1}^n \max \{y_i - \lambda, 0\} = S$$

לכן, על מנת למצוא את λ יש לפתור את המשוואה שלעיל. הסכום שווה לסכום כל ה- $y_i - \lambda$ אשר מקיימים $y_i - \lambda \geq 0$. מכאן שרק האיברים ב- y שהם מספיק גדולים יתרמו לסכום. אם כן, נמיין את האיברים ב- y ונשמור את תוצאות המיון בוקטור u . על מנת לתת לאיברים הגדולים את מלוא החשיבות נדרוש מהמיון לקיים $u_1 \geq u_2 \geq \dots \geq u_n$. כעת, נרצה לחפש את האינדקס הגדול ביותר ב- u שנסמנו ב- m המקיים $u_m - \lambda > 0$ וכך נדע שהאיברים אחריו אינם נחוצים לסכום. מתקיים:

$$\left(\sum_{i=1}^m u_i \right) - m\lambda = S$$

מכאן ש-

$$\lambda = \frac{(\sum_{i=1}^m u_i) - S}{m}$$

ובסה"כ הראינו כיצד בחרנו x_0 יחסית טוב בשיטת Projected Gradient Decent. ■

4.3 מספר מצב

תחילה, נציג את ההגדרה של מספר מצב (condition number) של מטריצה. נגדיר את M_{nk} להיות מרחב של מטריצות, כאשר $A \in M_{nk}$ אם מתקיים

$$A \leftarrow \begin{pmatrix} \square \\ \vdots \\ \square \end{pmatrix} \in \mathbb{R}^{nk}$$

כלומר ניתן להמיר את המטריצה לוקטור על ידי שרשור איברי המטריצה.
ניקח את הנורמה האוקלידית מעל $\mathbb{R}^n$:

$$\|x\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}}$$

נגדיר נורמה מעל M_n : $M = \|A\|_2 = \max_{x \neq \vec{0}} \frac{\|Ax\|_2}{\|x\|_2}$. נורמה זו מודדת עד כמה המיפוי המושרה על ידי אותה מטריצה יכול למתוח וקטורים. לעתים חשוב לבדוק עד כמה מיפוי המושרה על ידי מטריצה יכול לכווץ וקטורים. נגדיר:

$$m = \min_{x \neq \vec{0}} \frac{\|Ax\|_2}{\|x\|_2}$$

נבחין שמתקיים

$$m = \min_{x \neq \vec{0}} \frac{\|Ax\|_2}{\|x\|_2} = \min_{y \neq \vec{0}} \frac{\|y\|_2}{\|A^{-1}y\|_2} = \frac{1}{\max_{y \neq \vec{0}} \frac{\|A^{-1}y\|_2}{\|y\|_2}} = \frac{1}{\|A^{-1}\|_2}$$

כאשר $Ax = y$.

הגדרה: מטריצה סינגולרית היא מטריצה אשר יכולה למפות וקטורים שאינם וקטור האפס לוקטור האפס.

הערה: עבור מטריצה סינגולרית מתקיים $m = 0$ וכן אינה קיימת מטריצה הופכית.

נגדיר את מספר מצב של מטריצה להיות היחס בין המתיחה המקסימלית למתיחה המינימלית:

$$\text{cond}(A) = \frac{M}{m}$$

מן המפורט לעיל נקבל הגדרה שקולה עבור מצב מצב:

$$\text{cond}(A) = \|A\|_2 \|A^{-1}\|_2$$

הערה: מספר המצב של מטריצה סינגולרית מוגדר להיות אינסוף. מספר מצב סופי וגדול מציינ שהמטריצה קרובה להיות סינגולרית.

טענה: תהי $\nabla^2 f(x)$ ההסיאן של הבעיה הקמורה הנתונה. נניח כי f קמורה ממש ובנוסף

$$0 \prec mI \preceq \nabla^2 f(x) \preceq MI, \quad \forall x$$

$$\Updownarrow$$

$$m \leq \lambda_i(\nabla^2 f(x)) \leq M, \quad \forall x$$

אזי עבור גודל צעד $t = \frac{1}{M}$ Protective Gradient Decent יתכנס כמו

$$f(x_k) - f(x^*) \leq c^k (f(x_0) - f(x^*))$$

כאשר $c \leq 1 - \frac{m}{M}$ ו- $x^* = \arg \min_x f(x)$.
הערה: היחס $\frac{M}{n}$ הוא למעשה חסם עליון על מספר המצב של ההסיאן $\nabla^2 f(x)$, המוגדר להיות היחס בין הערך הסינגולרי המקסימלי לערך הסינגולרי המינימלי שלה.

הכוונה להוכחה: מאחר ש- Projective Gradient Decent זהה ל- Gradient Decent פרט לשלב נוסף בו מתבצעת הטלה, ההוכחה עבור Gradient Decent היא אותה ההוכחה עבור Projective Gradient Decent. מאחר שבדרך כלל לא יודעים את הערך של M , מבצעים line search. שתי שיטות line search שכיחות הן: exact line search ו- backtracking line search. ב- [1] מופיעה הוכחת ההתכנסות עבור כל אחת משתי השיטות.

מסקנה: כאשר משתמשים ב- Projective Gradient Decent, ההתכנסות לפתרון האופטימלי מושפעת ממספר המצב של מטריצת ההסיאן של הבעיה.

מקורות

Caramanis & Sanghavi: Lecture 4 in Large Scale Optimization. Link [1]